

Systemy Inteligentne – Projekt

Wielokryterialne podejmowanie decyzji w problemie rozmieszczenia turbin wiatrowych przy założeniu nieprecyzyjnego wolumenu produkcji energii

Spis treści:

1. Wstęp.....	2
2. Etap 1- Predykcja ilości produkowanej energii w elektrowni.....	2
3. Etap 2- Wielokryterialna optymalizacja rozmieszczenia turbin wiatrowych na obszarze przy nieprecyzyjnym wolumenie produkcji energii.....	5
4. Podsumowanie	8

1. WSTĘP

1.1 Zakres

Realizacja projektu z laboratorium Systemów Inteligentnych składa z dwóch części, obejmujących różne, choć związane ze sobą tematycznie, zagadnienia. Pierwsza część projektu obejmuje implementację systemu predykcji produkcji energii w elektrowni na podstawie wybranych danych przy wykorzystaniu modeli regresji wielowymiarowej oraz regresji przedziałowej. W ramach drugiej części zrealizowane zostało zadanie wielokryterialnej optymalizacji rozmieszczenia turbin wiatrowych na danym obszarze poprzez maksymalizację wyprodukowanej energii oraz jednoczesną minimalizację kosztu, metodą symulowanego wyżarzania. W zadaniu uwzględnione zostało również założenie nieprecyzyjnego wolumenu produkcji energii, obsłużone dodatkowym modelem regresji liniowej.

1.2 Narzędzia

Projekt został wykonany w języku programowania Python przy wykorzystaniu jego odpowiednich bibliotek, takich jak *pandas*, która umożliwia wczytanie oraz obróbkę danych, *numpy* – służącą do wyrażeń algebraicznych, *sklearn* – do tworzenia modeli uczenia maszynowego oraz *seaborn* i *matplotlib* do wizualizacji danych. Kod źródłowy został zamieszczony w repozytorium GitHub pod adresem: https://github.com/alicijadabrowska2301/SI_projekt

2. ETAP 1 – Predykcja ilości produkowanej energii w elektrowni

2.1 Cel i zakres

W ramach pierwszego etapu projektu zrealizowana została predykcja wartości produkcji energii dla danych z elektrowni o cyklu kombinowanym (CCPP) przy wykorzystaniu dwóch modeli: regresji wielowymiarowej oraz regresji wielowymiarowej przedziałowej, która podobnie do tej pierwszej pozwala na modelowanie zależności między zmiennymi niezależnymi a zmienną zależną, lecz jednocześnie uwzględniając podział zmiennej zależnej na przedziały. Celem tej części projektu było zbudowanie modelu regresji wielowymiarowej, który przewiduje wyprodukowaną energię na podstawie czterech zmiennych niezależnych: temperatura (T), ciśnienie otoczenia (AP), wilgotność względna (RH) i próżnia spalin (V). Zakres projektu obejmował przygotowanie danych, implementację regresji wielowymiarowej za pomocą modelu liniowego, dokonanie predykcji na zbiorze testowym i ocenę jakości modelu za pomocą różnych metryk, takich jak błąd bezwzględny średni (MAE), błąd średniokwadratowy (MSE), pierwiastek błędu średniokwadratowego (RMSE) i współczynnik determinacji (R²). W ramach realizacji regresji przedziałowej zakres zadania rozszerzony został o dyskretyzację zmiennej zależnej na 8 przedziałów oraz implementację regresji przedziałowej za pomocą modelu BayesianRidge. Na koniec dokonano predykcji na zbiorze testowym przy użyciu modelu przedziałowego i ocenę jego jakości.

2.2 Zbiór danych

Zbiór danych zawiera 9568 punktów danych zebranych z elektrowni o cyklu kombinowanym na przestrzeni 6 lat (2006-2011), kiedy elektrownia została ustawiona do pracy z pełnym obciążeniem. Funkcje obejmują średnie godzinowe zmienne otoczenia Temperatura (T), Ciśnienie otoczenia (AP), Wilgotność względna (RH) i Próżnia spalin (V) w celu przewidywania godzinowej produkcji energii elektrycznej netto (EP) zakładu.

Zbiór danych został pobrany w postaci pliku excel o rozszerzeniu .xlsx. ze strony internetowej o adresie: <https://archive.ics.uci.edu/ml/datasets/combined+cycle+power+plant>.

2.4 Realizacja projektu

Pierwszym etapem było wczytanie i odpowiednie przetworzenie wybranych danych. Dostępne atrybuty rozdzielono na zmienne zależne (wejściowe) oraz zmienną niezależną (wyjściową). Dane zostały podzielone na zbiór treningowy (x_train, y_train) i zbiór testowy (x_test, y_test) w proporcji 80:20 za pomocą metody train_test_split() z biblioteki sklearn.model_selection.

Następnie zbudowano model regresji wielowymiarowej za pomocą metody sklearn.linear_model.LinearRegression i dokonano predykcji na zbiorze testowym. Następnie obliczono metryki jakości modelu, takie jak MAE, MSE, RMSE i R2 (wyniki przedstawione będą w następnym punkcie).

Kolejnym krokiem było zbudowanie modelu regresji przedziałowej dla tych samych danych. Zastosowano dyskretyzację zmiennej zależnej na 8 przedziałów za pomocą metody KBinsDiscretizer. Następnie zaimplementowano model regresji przedziałowej za pomocą metody BayesianRidge. Dokonano predykcji na zbiorze testowym przy użyciu modelu przedziałowego i oceniono jego jakość za pomocą tych samych metryk. Ostatnim elementem była wizualizacja wyników (wykres ważności cech, wykresu rozrzutu).

2.5 Wyniki

Po zbudowaniu dwóch modeli regresji dokonano wizualizacji wyników. Na początek wykreślone zostały współczynniki kierunkowe i wyraz wolny dla obu modeli:

<pre>Współczynniki regresji: 0 AP 0.057 RH -0.159 V -0.230 AT -1.986 Wyraz wolny 460.25</pre>	<pre>Współczynniki regresji: AT: -0.016 V: -0.209 AP: -0.024 RH: 0.008 Wyraz wolny: 1.878</pre>
a)	b)


Rys.1. Parametry modeli regresji wielowymiarowej (a) oraz przedziałowej (b).

Wyznaczone zostały również metryki oceny jakości modelu:


<pre>MAE: 3.720 MSE: 23.299 RMSE: 4.827 R2 score: 92.869</pre>	<pre>MAE: 5.699 MSE: 50.765 RMSE: 7.125 R2 score: 82.832</pre>
a)	b)

Rys.2. Wartości błędów dla modeli regresji wielowymiarowej (a) oraz przedziałowej (b).

Kolejnym elementem wizualizacji były wykresy ważności cech oraz macierz korelacji cech dla modelu regresji wielowymiarowej:



Dla modelu regresji przedziałowej dodatkowo zwizualizowany został wykres ważności cech i rozrzutu:



2.6 Wnioski

Na podstawie wykreślonych wizualizacji oraz metryk można zauważyć, że model regresji wielowymiarowej lepiej dopasowuje się do danych, osiągając wynik miary R^2 na poziomie 92% dopasowania, co przewyższa model regresji przedziałowej o 10%. Dodatkowo wykres ważności cech dla obu modeli daje podobne wyniki, plasując temperaturę (zmienna AT) na pierwszym miejscu, jako cechę najbardziej wpływającą na wartość produkcji energii w elektrowni. Pozostałe cechy są zdecydowanie mniej znaczące. Z wyników realizacji predykcyjnych modeli regresji wielowymiarowej oraz przedziałowej można wysnuć wniosek, iż w celu zbadania liniowych zależności między zmiennymi zależnymi, korzystniej będzie użyć modelu wielowymiarowego, natomiast w celu bardziej wnikliwej analizy i zbadania wartości energii wobec zmiennych niezależnych pod kątem różnych jej przedziałów, zdecydowanie lepiej będzie wybrać model przedziałowy. Podsumowując, oba modele mogą znaleźć swoje zastosowanie w zależności od wymagań i potrzeb użytkownika.

3. ETAP 2 -Wielokryterialna optymalizacja rozmieszczenia turbin wiatrowych na obszarze przy nieprecyzyjnym wolumenie produkcji energii

3.1 Cel i zakres

Celem drugiego etapu projektu było rozwiązanie problemu rozmieszczenia wiatraków energetycznych na danym obszarze przy maksymalizacji wyprodukowanej energii oraz minimalizacji kosztu z założeniem nieprecyzyjnego wolumenu produkcji energii. Ten problem optymalizacji dwukryterialnej został rozwiązany metodą symulowanego wyżarzania. W ramach tej części projektu dla każdego obszaru wygenerowany został koszt oraz niepewny zakres produkcji energii w formie przedziału. W celu znalezienia optymalnego rozwiązania zbudowany został model regresji liniowej, zwracający najlepszą wartość energii z przedziału. Rozwiązanie zadania optymalizacji zostało rozszerzone o przypadek optymistyczny i pesymistyczny, uwzględniając dolną i górną granicę przedziału wartości produkcji energii.

3.2 Model matematyczny

Założenia:

M- liczba obszarów, na których mogą być rozmieszczone wiatraki,

N - liczba wiatraków energetycznych do rozmieszczenia,

$i \in \{1, 2, \dots, M\}$ – i oznacza i-ty obszar, na którym umieszczony może być wiatrak,

$j \in \{1, 2, \dots, N\}$ – j oznacza j-ty wiatrak do rozmieszczenia,

C_i – koszt instalacji wiatraka na i-tym obszarze,

E_i - wartość produkcji energii przez wiatrak na i-tym obszarze.

Zmienne decyzyjne:

x_i - zmienna decyzyjna dla i-tego obszaru, wskazuje czy na i-tym obszarze zainstalowany jest wiatrak energetyczny, czy nie, gdzie x_i przyjmuje wartości binarne (0 lub 1).

Funkcje celu:

W ramach optymalizacji dwukryterialnej określone zostały dwie funkcje celu: minimalizacja kosztu (1) oraz maksymalizacja wyprodukowanej energii (2)

$$\min_x \sum_{i=1}^M C_i \cdot x_i \quad (1) \qquad \max_x \sum_{i=1}^M E_i \cdot x_i \quad (2)$$

Ograniczenia:

Rozmieszczonych ma być N wiatraków: $\sum_{i=1}^M x_i = N$

Ograniczenia na zmienne decyzyjne: $x_i \in \{0, 1\}$

3.3 Realizacja projektu

Realizacja tej części projektu rozpoczęła się od podziału obszaru (kwadratu) na 100 mniejszych obszarów. Następnie dla każdego obszaru wylosowane zostały przedziały wartości produkcji energii osobno dla każdej godziny w ciągu doby (24 przedziały dla obszaru) jako górna i dolna granica wyprodukowanej energii (Lower Bound i Upper Bound). Wygenerowane dane zostały zapisane i przechowywane w stworzonej, przy pomocy biblioteki pandas, ramce danych *df_energy_per_hour*. Następnym krokiem było stworzenie drugiej ramki danych *df_general*, w której dla każdego z obszarów zsumowany został dobowy zakres produkcji energii jako pesymistyczna i optymistyczna wartość wyprodukowanej energii dla obszaru (Energy neg i Energy pos) oraz wylosowany został koszt związany z instalacją wiatraka.

Area	Hour	Lower Bound	Upper Bound
0	0	0	17.797588
1	0	1	18.881459
2	0	2	20.320415
3	0	3	17.822092
4	0	4	44.447624
...	...	...	...
2395	99	19	22.786314
2396	99	20	20.859971
2397	99	21	14.372047
2398	99	22	13.147586
2399	99	23	23.585479

2400 rows x 4 columns


Area	Energy neg	Energy pos	Cost
0	0	701.060552	1309.401530
1	1	1448.883412	2774.713305
2	2	2118.441843	4220.559746
3	3	2741.688873	5621.979245
4	4	3451.293631	7136.956575
...	...	...	...
95	95	69708.838646	139039.826655
96	96	70417.066573	140501.851703
97	97	71105.600142	141834.331755
98	98	71837.392309	143244.544802
99	99	72517.196352	144649.881641

100 rows x 4 columns

Rys 3.: Rysunek przedstawia odpowiednio ramki danych *df_energy_per_hour* i *df_general*


W kolejnym kroku wykonana została regresja liniowa dla danych godzinowych do oszacowania wartości energii na podstawie relacji między dolną i górną granicą energii. Regresja liniowa dopasowuje linię do punktów danych, a następnie przewiduje wartość energii dla określonego wejścia, która jest punktem środkowym między dolną i górną granicą. Takie podejście uwzględnia związek między dolną i górną granicą i zapewnia dokładniejsze oszacowanie wartości energii w tym zakresie. Poniżej przykładowe wykresy przedziałów produkcji energii dla 4 obszarów:

Wykres przedziału wartości energii dla przykładowych obszarów



Poniżej przedstawione zostały te same przedziały dla obszarów z dodatkową linią regresji, przedstawiającą wyestymowane wartości energii:


Wykres przedziału wartości energii wraz z linią regresji dla przykładowych obszarów



Kolejnym krokiem było zsumowanie wartości wyestymowanej energii z regresji liniowej do ramki danych `df_general`, z której następnie skorzystałyśmy do wykonania dwukryterialnej optymalizacji rozmieszczenia wiatraków energetycznych przy minimalizacji kosztu i maksymalizacji wyprodukowanej energii, z uwzględnieniem optymistycznego i pesymistycznego przypadku (górną i dolną granicę wartości energii). Optymalizacja została wykonana za pomocą heurystycznej metody symulowanego wyżarzania. Przyjęłyśmy następujące parametry algorytmu: temperatura początkowa = 100, współczynnik chłodzenia = 0.95, maksymalna liczba iteracji = 1000. Wyniki algorytmu przedstawione zostaną w kolejnym punkcie.


3.4 Wyniki

Po wykonaniu optymalizacji metodą symulowanego wyżarzania wyświetlone zostały optymalne rozwiązania oraz wartości funkcji celu:



Rys.5: Rysunek przedstawia wyniki optymalizacji dwukryterialnej: rozmieszczenie wiatraków na obszarach, wartości funkcji celu dla każdego z przypadków oraz pomocniczą siatkę rozmieszczenia.

Następnie wykreślone zostało również rozwiązanie optymalne wraz z jego pesymistycznym i optymistycznym przypadkiem na wykresie wartości kosztu od energii:



Rys5.: Rysunek przedstawia rozkład rozwiązań optymalizacji dla przypadku pesymistycznego i optymistycznego na wykresie kosztu i energii.

3.5 Wnioski

Po dokonaniu optymalizacji metodą symulowanego wyżarzania okazuje się, że wszystkie 3 przypadki: optymalny, pesymistyczny i optymistyczny osiągnęły to samo rozmieszczenie wiartaków jednak z różnymi wartościami funkcji celu. Rozwiązanie optymalne osiągnęło koszt 23488.5 oraz energię 542268.0, natomiast dla przypadku pesymistycznego wartości te osiągnęły zdecydowanie większe wartości zarówno kosztu jak i energii, a dla optymistycznego zdecydowanie większą wartość energii dla lekko wyższej wartości kosztu, co w takiej proporcji wydaje się najlepszym z tych trzech rozwiązań, co potwierdza fakt, że jest to optymistyczny przypadek.

4. Podsumowanie

Realizacja projektu pozwoliła na bliższe zapoznanie się z przypadkami niepewności przedziałowej zarówno w problemie wielokryterialnego podejmowania decyzji, jak również przy implementacji modeli uczenia maszynowego, a w szczególności regresji. Wykonanie powyżej opisanych zadań umożliwiło również realne zderzenie się z problemami, które są tematami kursu Systemy Inteligentne wraz ze zdobyciem praktycznych umiejętności ich rozwiązywania w środowisku programistycznym.